

MedHarmDiff Camelyon17-WILDS 实验报告

从真实数据 pipeline 到全量 ResNet18 诊断

报告日期	2026-07-06
项目分支	codex/mvp-benchmark
最新提交	e68332e Cap latent diffusion training pairs for full benchmarks
数据范围	Camelyon17-WILDS, 455,954 patches, 5 centers
报告定位	实验阶段汇报，不是论文贡献声明

核心结论

项目 pipeline 已经成立：真实 Camelyon17 数据、paper-safe split、target labels 不进训练、group overlap 为空、embedding-family benchmark 和 claim gate 都已跑通。但 diffusion 贡献尚未成立；全量 ResNet18 下 latent_diffusion_v0 仍低于最强非 diffusion baseline，因此不应开启 neural diffusion v1。

给老师的一句话汇报

我已经把多中心 harmonization 方向搭成了可复现的真实数据 benchmark，并在 Camelyon17-WILDS 上完成了 paper-safe full ResNet18 诊断。结果显示 ResNet18 表征显著提升整体性能，但提升主要被 identity/source_standardize/ridge 等强 baseline 吸收，latent diffusion v0 没有超过 claim gate。因此当前结论是继续暂停 diffusion 建模，先把项目定位为安全 benchmark 与失败边界诊断。

1. 研究问题与判定标准

本阶段的核心问题不是“能不能把 diffusion 跑起来”，而是：在真实 multi-center pathology setting 中，diffusion-style harmonization 是否在不使用 target labels 的前提下，超过强非 diffusion baseline。

判定项	要求	本轮 full ResNet18 结果
paper-safe split (论文安全划分)	train/val/test group overlap 全为空	通过: overlap 均为 []
target labels (目标域标签)	只允许评估, 不进入训练/调参	通过: uses_target_labels=False
target AUC margin (目标域增益)	latent diffusion >= best non-diffusion + 0.01	未通过: gain=-0.0021
clinical preservation (源域临床信号保留)	source_val_auc drop <= 0.01	通过: drop=0.0020
claim gate (主张门槛)	全部条件满足才可声称 diffusion contribution	baseline_not_beaten

当前决策
不启动 neural diffusion v1。继续投入更大 diffusion 模型前，必须先看到 full benchmark 中 latent diffusion v0 稳定超过最强 baseline；当前证据相反。

2. 数据、划分与安全边界

本轮实验使用 Camelyon17-WILDS 的真实 patch-level 数据。所有真实数据、embeddings、feature CSV 和结果均保存在 ignored data/ 与 results/ 下，未提交到 Git。

项目	数值/说明
总样本	455,954
center 数	5
center 分布	0: 59436, 1: 34904, 2: 85054, 3: 129838, 4: 146722
训练/验证/测试	train=302436, val=34904, test=85054
group 安全性	train-val/test-val/train-test overlap 均为空
confounding_status	pass

3. 实验路线

实验分为两个层次：先用 1200-row balanced smoke 验证 ResNet18 extraction、conversion 与 benchmark 路线；再运行全量 ResNet18 benchmark 作为主要诊断。

阶段	目的	结果
metadata probe	确认 center_id / label / patient_or_group_id / split_group 可用	通过；可构造 paper-safe split
color_stats_v0	先建立无模型/低成本表征 baseline	全量已跑；diffusion 未过 gate
ResNet18 smoke	验证 CUDA、ImageNet weights、512-dim feature 路线	1200-row paper-safe smoke 通过
ResNet18 full extraction	生成全量 stronger embedding	455,954 x 512 NPZ 成功
full benchmark	最终诊断 stronger embedding 下 diffusion 是否成立	claim_gate=baseline_not_beaten
scaling fix	解决 full-scale latent_diffusion_v0 内存扩展	训练 pair cap + float32；pytest 82 passed

重要实现修正


全量 benchmark 首次运行时，latent_diffusion_v0 试图构造 2,419,488 个训练 pairs，并在 float64 下申请约 18.5GB 内存。修复后默认最多使用 100,000 个 deterministic training pairs，并使用 float32 预分配。这是为了让 v0 在真实数据规模上可运行；它不改变“v0 不是 neural DDPM”的研究边界。

4. 表征与方法

类别	方法	说明
embedding	color_stats_v0	37 维颜色统计特征，用作低成本基线
embedding	resnet18_imagenet_v0	ImageNet ResNet18 512 维特征，CUDA 抽取，weights_source=torchvision_default_download
statistical	identity / source_standardize / center_mean	强非 diffusion baseline；不使用 target labels
learned denoising	ridge_denoising	feature-level ridge denoising baseline，不是 diffusion contribution
diffusion v0	latent_diffusion_v0	time-conditioned ridge diffusion-style v0，不是 neural diffusion v1
placeholder	diffusion_placeholder	用于确认接口和报告逻辑，不作为贡献

5. 主要结果

Full target AUC by embedding family and method



Embedding family	Samples	Dim	Best statistical	Ridge	Latent diffusion	Claim gate
color_stats_v0	455,954	37	0.8853	0.8991	0.8975	baseline_not_beaten
resnet18_imagenet_v0	455,954	512	0.9685	0.9685	0.9665	baseline_not_beaten

Full ResNet18 详细指标

Method	Family	Source val AUC	Target AUC	Target acc	Status
identity	statistical_baseline	0.9499	0.9685	0.8839	ok
source_standardize	statistical_baseline	0.9499	0.9685	0.8839	ok
center_mean	statistical_baseline	0.9466	0.9675	0.8863	ok
ridge_denoising	learned_denoising	0.9499	0.9685	0.8840	ok
latent_diffusion_v0	diffusion_v0	0.9479	0.9664	0.8769	ok
diffusion_placeholder	diffusion_placeholder	0.9499	0.9685	0.8839	placeholder

结果解读

ResNet18 明显提高了整体任务性能：best statistical target AUC 从 color_stats_v0 的 0.8853 提升到 ResNet18 的 0.9685。但这个提升主要被 identity/source_standardize/ridge 等非 diffusion baseline 吸收，而不是由 latent diffusion v0 获得。全量 ResNet18 下 latent_diffusion_v0 target AUC 为 0.9665，低于最强非 diffusion baseline 0.9685，margin=-0.0020。

6. 研究判断

项目基础设施已经成立
真实数据、group-safe split、feature extraction、benchmark、claim gate、summarizer、embedding-family comparison 都已打通。这说明项目已经从 synthetic scaffold 进入真实数据可诊断阶段。

diffusion 贡献尚未成立
当前不能写 diffusion harmonization improves Camelyon17。更准确的表述是：latent diffusion v0 was evaluated on paper-safe Camelyon17 feature benchmarks, but did not outperform strong non-diffusion baselines。

为什么不继续 neural diffusion v1

- 当前失败不是 pipeline 没跑通，而是 benchmark 已经显示 feature-level shift 可被简单 baseline 很好处理。
- full ResNet18 已经把表征质量拉到很高，但 latent diffusion 仍低于 identity/ridge。
- 如果直接上 neural DDPM/MLP score model，最可能结果是仍输给 baseline，或者 target 小幅提升但 source_val_auc 掉，claim gate 仍不过。
- 因此 neural diffusion v1 应作为条件触发项，而不是下一步默认路线。

7. 局限性与风险

局限	含义	当前处理方式
feature-level benchmark	不是 end-to-end pathology model; 只评估特征层 harmonization	报告中不声称临床应用或 pathology foundation contribution
ImageNet ResNet18	比 color stats 强，但不是 pathology-specific encoder	作为确认性 stronger embedding，不扩大为最终模型结论
site_auc 仍为 1.0	site identity 在特征中仍可被区分	claim gate 因 target margin 不足已经失败; site reduction 也未形成正贡献
latent_diffusion_v0 cap	为全量可运行引入 100k pair cap	明确标注为 scalable v0 diagnostic，不作为 neural diffusion
单数据集	当前只证明 Camelyon17 feature-level 场景下 baseline 主导	后续若换任务/表征，需要重新跑同一 gate

8. 下一步建议

优先级	行动	理由
现在	暂停 neural diffusion v1	full ResNet18 claim gate 未通过
现在	将阶段性成果整理为 benchmark/pipeline 进展	这是当前最稳妥、可向老师解释的贡献
谨慎	只在更有 domain-shift headroom 的任务上重新评估 diffusion	当前 Camelyon17 feature-level baseline 太强
暂不做	ResNet50 full / pathology foundation encoder / diffusion 超参搜索	会消耗大量时间，但当前失败原因不支持立即扩展

建议对老师的表述

我已经把多中心 harmonization 方向搭成了可复现 pipeline，并在 Camelyon17-WILDS 上完成了 paper-safe full benchmark。结果显示 ResNet18 表征显著优于 color statistics，但 diffusion v0 仍没有超过最强非 diffusion baseline，claim gate 没通过。因此我现在不会直接上更大的 diffusion，而是把当前阶段定位为真实数据 benchmark 与失败边界诊断。

附录 A. 关键命令与环境

项目	记录
Torch/CUDA	torch 2.11.0+cu128; torchvision 0.26.0+cu128; CUDA available; NVIDIA GeForce RTX 4090 Laptop GPU
ResNet extraction	scripts/extract_camelyon17_patch_embeddings.py --extractor resnet18_imagenet_v0 --allow-download-weights --batch-size 32 --device cuda
Full NPZ	data/camelyon17/embeddings/camelyon17_resnet18_imagenet_v0_full.npz (ignored)
Full feature CSV	data/camelyon17/features/camelyon17_resnet18_imagenet_v0_full_features.csv (ignored)
Full benchmark result	results/camelyon17_resnet18_full_benchmark_papersafe/full/ (ignored)
Embedding family result	results/camelyon17_embedding_family_full_papersafe/ (ignored)
Verification	python -m py_compile ... passed; pytest -q: 82 passed in 24.48s

附录 B. 产物与版本控制

本报告对应 Git commit: e68332e Cap latent diffusion training pairs for full benchmarks。真实数据、embedding、feature CSV 和 benchmark results 仍位于 .gitignore 覆盖的 data/** 与 results/** 下；报告 PDF 与 Markdown 源文件保存在 output/pdf/，用于老师汇报。