

MedHarmDiff Camelyon17-WILDS 实验报告

报告日期: 2026-07-08 实验日期: 2026-07-06 分支: codex/mvp-benchmark

结论: 当前 Camelyon17 feature-level 设定下 diffusion 路线不可行。全量 ResNet18 下 latent_diffusion_v0 target AUC=0.9665, 低于最强非 diffusion baseline 0.9685, 差值=-0.0020, 未达到 +0.01 claim gate。

1. 我做了哪些实验

- 准备并验证 Camelyon17-WILDS 真实数据: 455,954 个 patch, 5 个 center。
- 导出 metadata.csv, 确认 center_id、label、patient_or_group_id、split_group 可用于 group-safe benchmark。
- 构建 paper-safe split: train=302,436, val=34,904, test=85,054; train/val/test group overlap 均为空。
- 生成 color_stats_v0 (37 维) 和 ResNet18 ImageNet embedding (512 维), 并转成 feature CSV。
- 运行 group-safe Camelyon17 benchmark 和 embedding-family benchmark。
- 评估 identity、source_standardize、center_mean、ridge_denoising、latent_diffusion_v0、diffusion_placeholder。

2. 实验结果

Embedding	Samples	Dim	Best statistical AUC	Ridge AUC	Latent diffusion AUC	Claim gate
color_stats_v0	455,954	37	0.8853	0.8991	0.8975	baseline_not_beaten
resnet18_imagenet_v0	455,954	512	0.9685	0.9685	0.9665	baseline_not_beaten

安全检查: paper_safe_split=True; uses_target_labels=False; group_overlap_train_val=[]; group_overlap_train_test=[]; group_overlap_val_test=[]; confounding_status=pass。

3. 结论

ResNet18 明显提升了整体任务性能, 但提升主要被 identity/source_standardize/ridge 等非 diffusion baseline 吸收。全量 ResNet18 下 latent_diffusion_v0 没有超过最强 baseline, claim gate 仍为 baseline_not_beaten。

因此, 当前结论不是 pipeline 失败, 而是当前 Camelyon17 feature-level 任务中, 强 baseline 已经能很好处理该表征空间中的 shift。继续投入 neural diffusion v1 不合理, 除非换到更有 domain-shift headroom 的任务、表征或数据设定, 并重新通过同样的 paper-safe claim gate。